

1. Distribution of Daily Rental Count (cnt)

این نمودار توزیع تعداد کل اجاره‌های روزانه (cnt) را نشان می‌دهد. داده شامل 731 روز است. مقدار cnt از 22 تا 8714 تغییر می‌کند و میانگین آن حدود 4504 و میانه حدود 4548 است.

نکته مهم این است که توزیع cnt برخلاف بسیاری از متغیرهای شمارشی، شکل کاملاً شدیداً چوله‌ای ندارد. Skewness برابر 0.0474- است که تقریباً صفر است؛ بنابراین توزیع از نظر تقارن، تقریباً متقارن است. در عین حال، توزیع کاملاً نرمال نیست و پراکندگی نسبتاً زیادی دارد.

چرا نمودار این‌طوری شده؟

چون تعداد اجاره‌ها فقط تحت تأثیر یک عامل نیست. دما، آب‌وهوا، سال، فصل، تعطیلات و سایر شرایط روزانه روی تقاضا اثر می‌گذارند. از طرف دیگر، سیستم در سال ۲۰۱۲ نسبت به ۲۰۱۱ محبوب‌تر شده و سطح تقاضا افزایش پیدا کرده است. بنابراین cnt حاصل ترکیب چند الگوی مختلف است.

چه تصمیمی در پروژه ایجاد کرد؟

این نمودار باعث شد cnt را به‌عنوان یک متغیر عددی پیوسته‌مانند برای مدل‌سازی در نظر بگیریم و از مدل‌های Regression استفاده کنیم. همچنین مشخص شد که نیازی نیست صرفاً به دلیل اینکه cnt یک count است، حتماً آن را به یک متغیر categorical تبدیل کنیم.

2. Distribution of Normalized Temperature (temp)

این نمودار توزیع temp را نشان می‌دهد. temp در دیتاست از قبل نرمال‌سازی شده و تقریباً بین 0 و 1 قرار دارد. میانگین آن حدود 0.495 و میانه حدود 0.498 است. بنابراین دما در دیتاست در محدوده نسبتاً گسترده‌ای مشاهده شده و فقط در یک بخش بسیار محدود متمرکز نیست.

چرا نمودار این‌طوری شده؟

چون داده مربوط به روزهای مختلف دو سال است و فصل‌های متفاوت را شامل می‌شود. بنابراین روزهای سرد و گرم هر دو در دیتاست حضور دارند. توزیع دما نتیجه تغییر طبیعی دما در طول سال است.

چه تصمیمی در پروژه ایجاد کرد؟

این نمودار همراه با Scatter Plot و Correlation Matrix نشان داد که temp یک کاندید بسیار مهم برای پیش‌بینی cnt است. به همین دلیل اولین مدل‌ها عمده با فقط temp ساخته شدند تا ببینیم دما به تنهایی چقدر می‌تواند تقاضا را توضیح دهد.

3. Distribution of Normalized Humidity (hum)

این نمودار توزیع رطوبت نسبی را نشان می‌دهد. میانگین hum حدود 0.628 و میانه حدود 0.627 است. بنابراین بخش قابل توجهی از روزها در محدوده رطوبت متوسط تا نسبتاً بالا قرار گرفته‌اند.

اما نکته مهم‌تر این است که توزیع رطوبت به تنهایی نمی‌گوید که این متغیر چقدر برای پیش‌بینی تقاضا مفید است؛ برای این کار باید رابطه آن با cnt را بررسی کنیم.

چرا نمودار این‌طوری شده؟

رطوبت تابع شرایط جوی و فصل است و در طول سال تغییر می‌کند. بنابراین یک توزیع یکنواخت یا یک مقدار ثابت انتظار نمی‌رود.

چه تصمیمی در پروژه ایجاد کرد؟

در مرحله EDA مشخص شد که hum با cnt رابطه منفی دارد، اما این رابطه بسیار ضعیف‌تر از رابطه دما است. بنابراین hum به تنهایی به عنوان مدل اصلی انتخاب نشد، اما در Multiple Regression وارد شد تا بخشی از تغییرات تقاضا که دما توضیح نمی‌دهد، پوشش داده شود.

4. Distribution of Normalized Wind Speed (windspeed)

این نمودار توزیع سرعت باد را نشان می‌دهد. میانگین windspeed حدود 0.190 و میانه حدود 0.181 است. بیشتر مقادیر در سرعت‌های پایین تا متوسط متمرکز شده‌اند و مقادیر بسیار بالا کمتر دیده می‌شوند.

چرا نمودار این‌طوری شده؟

در اغلب روزهای دیتاست سرعت باد در محدوده نسبتاً پایین‌تری قرار دارد و روزهای با باد بسیار شدید تعداد کمتری دارند.

چه تصمیمی در پروژه ایجاد کرد؟

Correlation نشان داد:

$$\text{windspeed} \leftrightarrow \text{cnt} = -0.2345$$

یعنی رابطه منفی وجود دارد، اما ضعیف است. بنابراین باد به تنهایی مدل مناسبی برای پیش‌بینی تقاضا نیست، ولی برای Multiple Regression ارزش دارد که به‌عنوان یک متغیر کمکی وارد مدل شود.

5. Actual cnt Distribution vs. Synthetic Normal Distribution

این نمودار توزیع واقعی cnt را با یک توزیع نرمال مصنوعی که با میانگین و انحراف معیار واقعی داده ساخته شده، مقایسه می‌کند. نتایج واقعی:

$$\text{Skewness} = -0.0474 \quad \bullet$$

$$\text{Excess Kurtosis} = -0.8119 \quad \bullet$$

Skewness تقریباً صفر است؛ بنابراین توزیع از نظر تقارن بسیار نزدیک به متقارن است. اما نمودار کاملاً روی منحنی نرمال منطبق نیست. تفاوت‌هایی در شکل کلی و tail ها دیده می‌شود.

چرا نمودار این طوری شده؟

تقاضای دوچرخه حاصل یک فرآیند ساده و تک‌عاملی نیست. مثلاً:

• آب‌وهوای خوب → افزایش تقاضا

• باران/برف → کاهش تقاضا

• سال ۲۰۱۲ → سطح تقاضای بالاتر

• فصل → تغییر سطح تقاضا

• دما → تغییر رفتار کاربران

ترکیب این عوامل باعث می‌شود توزیع کلی تقریباً bell-shaped باشد ولی دقیقاً Normal نباشد.

چه تصمیمی در پروژه ایجاد کرد؟

تصمیم مهم این بود که تقاضا را کاملاً Normal فرض نکنیم. یعنی مدل‌سازی بر اساس داده واقعی انجام شد و از این نمودار صرفاً برای شناخت توزیع استفاده شد، نه اینکه بر اساس آن یک فرض سخت و غیرواقعی وارد مدل شود.

6. Distribution of Daily Rentals by Year

این Boxplot یکی از مهم‌ترین نمودارهای پروژه است. تقاضای ۲۰۱۱ و ۲۰۱۲ به شکل واضحی از هم جدا شده‌اند. میانه:

• $2011 = 3740$

• $2012 = 5927$

و میانگین‌ها:

• $2011 \approx 3406$

• 5600 $\approx$ 2012

یعنی سطح تقاضا در ۲۰۱۲ به طور قابل توجهی بالاتر است.

چرا نمودار این طوری شده؟

مهم ترین توضیح موجود در پروژه این است که سیستم bike-sharing در سال دوم محبوب تر شده است. بنابراین فقط تغییرات آب و هوایی باعث تغییر cnt نشده؛ یک روند زمانی/رشد سیستم نیز وجود دارد.

چه تصمیمی در پروژه ایجاد کرد؟

این نمودار مستقیماً یکی از مهم ترین تصمیم های مدل سازی را ایجاد کرد: سال (yr) باید در مدل Multiple Regression وجود داشته باشد. همچنین باعث شد Train/Test به صورت زمانی تقسیم شود، نه random چون اگر داده های ۲۰۱۱ و ۲۰۱۲ را کاملاً تصادفی قاطی کنیم، مدل آینده را هم در Train خواهد دید و ارزیابی واقع بینانه نخواهد بود.

7. Temperature vs. Daily Demand

این نمودار رابطه temp و cnt را نشان می دهد. روند کلی واضحاً مثبت است: با افزایش دما، تعداد اجاره های روزانه معمولاً افزایش پیدا می کند. اما نقاط کاملاً روی یک خط قرار ندارند؛ یعنی دما به تنهایی توضیح دهنده کل تقاضا نیست. نکته مهم دیگر این است که در نمودار، داده های ۲۰۱۲ نسبت به ۲۰۱۱ در سطح بالاتری قرار گرفته اند. همچنین رابطه کاملاً خطی نیست و کمی curvature دیده می شود؛ در دماهای خیلی بالا افزایش تقاضا می تواند کندتر شود یا حتی کمی افت کند.

چرا نمودار این طوری شده؟

چون دما یکی از عوامل مهم تقاضاست، اما عوامل دیگری مثل سال، رطوبت، باد، روز کاری و تعطیلات هم زمان اثر دارند. ضمن اینکه دو سال رفتار متفاوتی دارند.

چه تصمیمی در پروژه ایجاد کرد؟

سه تصمیم متوالی ایجاد کرد:

۱. temp به عنوان اولین feature مدل انتخاب شد .

۲. Polynomial Regression برای بررسی non-linearity امتحان شد .

۳. بعداً مشخص شد که دما به تنهایی کافی نیست و باید Multiple Regression ساخته شود.

8. Humidity vs. Daily Demand

در این نمودار روند کلی کمی منفی است، اما نقاط بسیار پراکنده‌اند.

Correlation واقعی:

$$r = -0.1007$$

بنابراین رابطه با تقاضا بسیار ضعیف است. یعنی افزایش رطوبت ممکن است با کاهش تقاضا همراه باشد، اما این رابطه آن قدر قوی نیست که بتوان از رطوبت به تنهایی تقاضا را به خوبی پیش‌بینی کرد.

چرا نمودار این‌طوری شده؟

چون رطوبت احتمالاً از طریق شرایط کلی آب‌وهوا روی رفتار کاربران اثر می‌گذارد، اما اثر آن با عوامل دیگر مخلوط شده است. مثلاً یک روز می‌تواند مرطوب باشد ولی دمای مطلوب و شرایط مناسب دیگری داشته باشد.

چه تصمیمی در پروژه ایجاد کرد؟

hum به عنوان مدل تک متغیره انتخاب نشد، اما به Multiple Regression اضافه شد.

9. Wind Speed vs. Daily Demand

رابطه کلی منفی است، اما پراکندگی بسیار زیاد است.

Correlation: $r = -0.2345$

پس نسبت به رطوبت رابطه کمی قوی تر است، اما هنوز رابطه ضعیفی محسوب می شود.

چرا نمودار این طوری شده؟

باد شدید می تواند استفاده از دوچرخه را ناخوشایندتر کند، اما تنها بخشی از رفتار کاربران را توضیح می دهد. به همین دلیل نقاط پراکنده هستند و یک الگوی واضح و باریک دیده نمی شود.

چه تصمیمی در پروژه ایجاد کرد؟

مثل hum، این متغیر به تنهایی برای مدل مناسب نبود، ولی در Multiple Regression حفظ شد تا اطلاعات اضافی را به مدل بدهد.

10. Correlation Matrix: Weather Variables & Demand

این Heatmap نتایج روابط عددی را به شکل خلاصه نشان می دهد:

رابطه	Correlation
cnt با temp	+0.6275
cnt با hum	-0.1007
cnt با windspeed	-0.2345

مهم‌ترین عدد بدون تردید $\text{temp} \rightarrow \text{cnt}$ است. 0.6275 یک رابطه مثبت نسبتاً قوی محسوب می‌شود، در حالی که دو متغیر دیگر رابطه بسیار ضعیف‌تری دارند.

چرا Heatmap این‌طور شده؟

چون الگوی Scatter Plot ها را به صورت عددی خلاصه می‌کند. دما بیشترین ارتباط را با تقاضا دارد؛ رطوبت کمترین ارتباط را دارد و باد نیز رابطه منفی ضعیفی دارد. البته این نمودار Correlation است، نه Causation. یعنی نمی‌توان صرفاً از آن نتیجه گرفت که افزایش دما به صورت علی باعث افزایش مشخصی در اجاره شده است.

چه تصمیمی در پروژه ایجاد کرد؟

این نمودار مبنای رتبه‌بندی اولیه Feature ها در EDA شد:

$\text{temp} > \text{windspeed} > \text{hum}$

اما پروژه فقط بر اساس correlation تصمیم نگرفت؛ چون هدف پیش‌بینی است، در نهایت چند feature هم‌زمان وارد Multiple Regression شدند.

11. cnt Distribution: Train vs Test

این نمودار توزیع cnt را بین Train و Test مقایسه می‌کند. داده‌ها به صورت زمانی تقسیم شده‌اند:

• Train: 584 رکورد / ۷۹.۹ %

• Test: 147 رکورد / ۲۰.۱ %

• Train: از ۲۰۱۱-۰۱-۰۱ تا ۲۰۱۲-۰۸-۰۶

• Test: از ۲۰۱۲-۰۸-۰۷ تا ۲۰۱۲-۱۲-۳۱

میانگین Train:

4153.6

میانگین: Test

5897.8

اختلاف:

+1744.2

این اختلاف بسیار مهم است.

چرا نمودار این طوری شده؟

چون Test مربوط به بخش پایانی زمان است و بخش پایانی دیتاست عمدتاً در ۲۰۱۲ قرار دارد؛ در حالی که تقاضای ۲۰۱۲ نسبت به ۲۰۱۱ به شکل محسوسی بیشتر شده است. پس Train و Test از نظر سطح تقاضا دقیقاً یک توزیع ندارند.

چه تصمیمی در پروژه ایجاد کرد؟

این نمودار باعث شد عملکرد ضعیف مدل‌های تک‌متغیره را اشتباه به عنوان صرفاً Overfitting تفسیر نکنیم. مشکل اصلی این بود که مدل فقط temp را می‌دید، ولی نمی‌توانست رشد تقاضا در طول زمان را بفهمد. بنابراین yr وارد Multiple Regression شد.

12. cnt Boxplot: Train vs Test

این Boxplot همان Distribution Shift را از زاویه دیگری نشان می‌دهد. موقعیت مرکزی Test بالاتر از Train است و دامنه مقادیر آن نیز متفاوت است. بنابراین Test واقعاً یک نسخه تصادفی از Train نیست؛ بلکه یک دوره زمانی جدیدتر است.

چرا نمودار این طوری شده؟

چون داده به صورت **chronological split** تقسیم شده:

Train → اول 80%

Test → آخر 20%

و در این فاصله سیستم رشد کرده است.

چه تصمیمی در پروژه ایجاد کرد؟

این نمودار تأیید کرد که روش تقسیم زمانی انتخاب درستی بوده است. ممکن بود **random split** نمره‌های ظاهراً بهتری بدهد، ولی چنین ارزیابی‌ای به سناریوی واقعی «پیش‌بینی آینده با استفاده از گذشته» وفادار نبود.

13. Simple Linear Regression: temp → cnt

اولین مدل واقعی پروژه فقط از **temp** برای پیش‌بینی **cnt** استفاده کرده است.

نتایج:

$$R^2 \text{ Train} = 0.4691 \quad \bullet$$

$$R^2 \text{ Test} = -0.4851 \quad \bullet$$

در **Train**، دما حدود 46.9٪ از واریانس تقاضا را توضیح می‌دهد. اما **Test R^2** منفی شده است. **R^2** منفی یعنی مدل روی **Test** حتی از یک مدل بسیار ساده که صرفاً میانگین **Test** را پیش‌بینی کند، عملکرد بهتری نداشته است.

چرا نمودار و عملکرد این طوری شده؟

مشکل اصلی فقط خطی بودن مدل نیست. مدل فقط این اطلاعات را دارد:

temp → cnt

اما نمی‌داند که:

2012 $\neq$ 2011

یعنی رشد سیستم را نمی‌بیند. در نتیجه رابطه‌ای که در Train یاد گرفته، روی سطح تقاضای بالاتر Test خوب منتقل نمی‌شود.

چه تصمیمی در پروژه ایجاد کرد؟

این مدل نشان داد:

Temperature مهم است، اما Temperature alone کافی نیست.

به همین دلیل پروژه به سمت Polynomial Regression و سپس Multiple Regression رفت.

14. Polynomial Regression Degree 2: temp $\rightarrow$ cnt

درجه ۲ اجازه می‌دهد رابطه بین دما و تقاضا خمیده باشد، نه فقط یک خط مستقیم. نتایج:

$$R^2 \text{ Train} = 0.5080 \quad \bullet$$

$$R^2 \text{ Test} = -0.3175 \quad \bullet$$

بنابراین نسبت به: Linear Regression

Train:

$$0.4691 \rightarrow 0.5080$$

بهبود داشته است.

Test:

$$-0.4851 \rightarrow -0.3175$$

Test هم بهتر شده، اما همچنان منفی است.

چرا نمودار این طوری شده؟

چون رابطه temp و cnt کمی nonlinear است. بنابراین یک منحنی درجه ۲ بهتر از یک خط می تواند curvature موجود در داده را تقریب بزند. اما مشکل اصلی یعنی تغییر سطح تقاضا بین سال ها همچنان باقی است.

چه تصمیمی در پروژه ایجاد کرد؟

مشخص شد Polynomial Regression می تواند رابطه دما را بهتر مدل کند، اما Polynomial کردن temp مشکل زمانی/سال را حل نمی کند. پس این مدل به عنوان مدل نهایی انتخاب نشد.

15. Polynomial Regression Degree 3: $\text{temp} \rightarrow \text{cnt}$

مدل درجه ۳ انعطاف پذیری بیشتری دارد. نتایج:

$$R^2 \text{ Train} = 0.5209 \quad \bullet$$

$$R^2 \text{ Test} = -0.3138 \quad \bullet$$

در Train نسبت به Degree 2 کمی بهتر شده:

$$0.5080 \rightarrow 0.5209$$

اما در Test فقط کمی تغییر کرده:

$$-0.3175 \rightarrow -0.3138$$

یعنی افزایش پیچیدگی تقریباً ارزش عملی خاصی ایجاد نکرده است.

چرا نمودار این طوری شده؟

مدل درجه ۳ می‌تواند curvature بیشتری را دنبال کند، بنابراین روی Train کمی بهتر fit می‌شود. ولی اطلاعات جدید مهمی درباره رشد سالانه تقاضا به مدل اضافه نشده است. در نتیجه مشکل اصلی همچنان باقی می‌ماند.

چه تصمیمی در پروژه ایجاد کرد؟

Degree 3 ارزش پیچیدگی اضافی را ندارد، چون بهبود Train بسیار کم است و Test تقریباً تغییری نکرده. بنابراین پروژه به جای پیچیده‌تر کردن رابطه temp، به سمت اضافه کردن Feature های واقعی و معنادار رفت.

16. Final Model Comparison: R^2 Train vs. R^2 Test

این مهم‌ترین نمودار مدل‌سازی پروژه است.

مدل‌ها:

Model	R^2 Train	R^2 Test
Linear Regression	0.4691	-0.4851
Polynomial Degree 2	0.5080	-0.3175
Polynomial Degree 3	0.5209	-0.3138
Multiple Regression	0.7502	0.4000
Multiple Regression + StandardScaler	0.7502	0.4000

واضح‌ترین اتفاق نمودار این است که با ورود به Multiple Regression، R^2 Test از مقادیر منفی به 0.4000 می‌رسد. این یک جهش بسیار مهم است.

چرا Multiple Regression بهتر شده؟

مدل نهایی از این شش feature استفاده کرده:

Temp,hum,windspeed,yr,workingday,holiday.

در نتیجه مدل دیگر فقط به دما وابسته نیست. مهم‌تر از همه، yr وارد مدل شده و به مدل اجازه داده بخشی از روند افزایش تقاضا در طول زمان را درک کند. ضرایب مدل هم این جهت‌ها را نشان داده‌اند:

temp: +6113.59 •

hum: -1960.74 •

windspeed: -3736.14 •

yr: +1742.74 •

workingday: +29.79 •

holiday: -442.74 •

بنابراین مدل یک تصویر چندبعدی‌تر از تقاضا می‌سازد.

چه تصمیمی در پروژه ایجاد کرد؟

این نمودار عملاً انتخاب مدل نهایی را مشخص کرد:

Multiple Linear Regression با 6 feature، مدل نهایی پروژه شد. دلیل انتخاب فقط

R^2 Train بالاتر نبود؛ مهم‌تر از آن این است که:

$\text{Test } R^2 = 0.4000$

و این در مقایسه با تمام مدل‌های تک‌متغیره بسیار بهتر است.

StandardScaler تصمیم مربوط به 17.

در نمودار/مقایسه نهایی، مدل:

Multiple Regression + StandardScaler

دقیقاً همان عملکرد مدل Multiple Regression را دارد:

• Train = 0.7502

• Test = 0.4000

چون StandardScaler اطلاعات جدیدی به داده اضافه نمی‌کند؛ فقط مقیاس feature ها را تغییر می‌دهد:

$$z = \frac{x - \mu}{\sigma}$$

Linear Regression معمولی نسبت به این تبدیل خطی از نظر قدرت پیش‌بینی invariant است. پس طبیعی است که R^2 تغییر نکند.

چه تصمیمی در پروژه ایجاد کرد؟

نتیجه پروژه این نبود که Scaling بد است. بلکه Scaling برای OLS Linear Regression باعث بهبود عملکرد نشد، اما برای مقایسه اندازه ضرایب مفید است. بعد از Scaling، هر coefficient تقریباً اثر یک تغییر یک انحراف معیار در آن feature را نشان می‌دهد؛ بنابراین مقایسه اهمیت نسبی feature ها راحت‌تر می‌شود.

جمع‌بندی نهایی نمودارها و مسیر تصمیم‌گیری پروژه

مرحله ۱ — شناخت Target

Distribution of Daily Rental Count (cnt)



cnt توزیع نسبتاً متقارن دارد، اما کاملاً Normal نیست و تغییرپذیری قابل توجهی دارد.

مرحله ۲ — شناخت Feature های آب و هوایی

temp, hum و windspeed توزیع‌های متفاوتی دارند.



بررسی رابطه آنها با Target

مرحله ۳ — پیدا کردن مهم‌ترین متغیر

Temperature vs. Daily Demand



رابطه مثبت و نسبتاً قوی.

Correlation Matrix: Weather Variables & Demand



→ temp = 0.6275 قوی‌ترین ارتباط.

مرحله ۴ — بررسی غیرخطی بودن

Polynomial Regression Degree 2



کمی بهتر از Linear

Polynomial Regression Degree 3



بهبود بسیار ناچیز → پیچیدگی بیشتر توجیه ندارد.

مرحله ۵ — کشف عامل بسیار مهم زمان

Distribution of Daily Rentals by Year



2012 به شکل واضح تقاضای بالاتری دارد.

بنابراین فقط temp کافی نیست.

مرحله ۶ — طراحی ارزیابی واقعی

cnt Distribution: Train vs Test



Train و Test به دلیل روند زمانی متفاوت اند.

بنابراین Temporal Split حفظ شد.

مرحله ۷ — مدل چند متغیره

Multiple Regression:

temp + hum + windspeed + yr + workingday + holiday



R^2 Test = 0.4000

در حالی که بهترین مدل تک متغیره R^2 Test آن فقط -0.3138 بود.

مرحله ۸ — بررسی Scaling +++++

بدون تغییر R^2 = Scaling:



Scaling عملکرد Linear Regression را بهتر نکرد، اما برای مقایسه ضرایب مفید است.

نتیجه گزارش پروژه

مهم‌ترین نتیجه این پروژه این نیست که «دما مهم‌ترین عامل است». نتیجه کامل‌تر این است که تحلیل اکتشافی نشان داد که دما با ضریب همبستگی ۰.۶۲۷۵ قوی‌ترین رابطه مستقیم را با تقاضای روزانه دارد، اما تحلیل مدل‌ها نشان داد که دما به تنهایی برای پیش‌بینی تقاضای آینده کافی نیست. مدل‌های Linear و Polynomial که تنها از دما استفاده می‌کردند، علی‌رغم عملکرد نسبتاً مناسب روی داده‌های آموزشی، روی داده‌های آزمون به R^2 منفی رسیدند. بررسی توزیع تقاضا در سال‌های ۲۰۱۱ و ۲۰۱۲ و همچنین مقایسه Train و Test نشان داد که یک Distribution Shift زمانی قابل توجه وجود دارد؛ میانگین تقاضای Test حدود ۱۷۴۴ واحد بیشتر از Train بود. در نتیجه، متغیرهایی مانند yr، hum، windspeed، workingday و holiday در کنار temp وارد Multiple Regression شدند. این مدل توانست R^2 آزمون را به ۰.۴۰۰۰ برساند و در مقایسه با مدل‌های تک‌متغیره عملکرد بهتری ارائه دهد. بنابراین مدل نهایی پروژه، Multiple Linear Regression با شش feature انتخاب شده است. نکته مهم اینکه casual و registered وارد مدل نشده‌اند، یک تصمیم عمدی و ضروری بوده است چون $cnt = casual + registered$ و استفاده از آنها برای پیش‌بینی cnt باعث Data Leakage و در واقع دادن جواب به مدل می‌شد. کد نهایی هم این موضوع را بررسی و تایید کرده است.