

آیا تقاضای روزانه دوچرخه تقریباً Normal است؟

برای بررسی توزیع متغیر هدف (cnt) از Histogram و مقایسه آن با یک توزیع نرمال استفاده شد.

نتایج نشان داد که متغیر هدف (cnt) کاملاً از توزیع نرمال پیروی نمی‌کند و انحراف‌هایی نسبت به توزیع نرمال مشاهده می‌شود.

اگرچه بخش مرکزی داده‌ها تا حدودی ساختاری مشابه توزیع نرمال دارد، اما شکل کلی توزیع واقعی دقیقاً با منحنی نرمال منطبق نیست. وجود افزایش‌های ناگهانی (Spike) در برخی محدوده‌ها نشان می‌دهد که این تفاوت می‌تواند ناشی از وجود عوامل مختلف مؤثر بر تقاضا مانند:

- شرایط آب‌وهوایی
- فصل
- ویژگی‌های زمانی
- رفتار کاربران

باشد.

Evidence:

- Histogram متغیر cnt
- مقایسه Histogram واقعی با Normal Distribution

Conclusion:

متغیر هدف (cnt) رفتار تقریباً نزدیک به نرمال دارد، اما به دلیل وجود عوامل مختلف مؤثر بر تقاضا، توزیع آن کاملاً نرمال نیست.

دما، رطوبت یا سرعت باد کدام رابطه روشن‌تری با تقاضا دارد؟

برای بررسی رابطه بین متغیرهای آب‌وهوایی و تقاضای روزانه دوچرخه، از Correlation Matrix و نمودارهای Scatter استفاده شد.

نتایج همبستگی:

Feature	Correlation with cnt	Interpretation
temp	+0.627	Moderately strong positive linear relationship
hum	-0.101	Weak negative linear relationship
windspeed	-0.235	Weak negative linear relationship

در بین متغیرهای آب‌وهوایی بررسی‌شده، دما (temp) بیشترین مقدار همبستگی خطی با متغیر هدف (cnt) را دارد.

این نتیجه نشان می‌دهد که دما در مقایسه با رطوبت و سرعت باد، رابطه خطی واضح‌تری با تغییرات تقاضا دارد.

Evidence

- Correlation Matrix
- Scatter Plot بین cnt, temp, hum, windspeed

Conclusion

دما در بین متغیرهای آب‌وهوایی بررسی‌شده، قوی‌ترین رابطه خطی را با تقاضای دوچرخه دارد.

با این حال، همبستگی نشان‌دهنده رابطه آماری است و به معنی رابطه علی قطعی نیست.

آیا Polynomial رابطه دما و تقاضا را بهتر نمایش داده است؟

برای بررسی اینکه آیا رابطه بین دما و تقاضا کاملاً خطی است یا خیر، مدل‌های Linear Regression و Polynomial Regression با استفاده از ویژگی temp ساخته شدند.

نتایج مدل‌ها روی داده: Test:

Model	Test R ²
Linear Regression (temp only)	-0.485
Polynomial Degree 2	-0.317
Polynomial Degree 3	-0.314

نتایج نشان می‌دهد که مدل‌های Polynomial نسبت به Linear Regression تک‌متغیره مقدار R² بهتری داشته‌اند.

این موضوع نشان می‌دهد Polynomial توانسته است بخشی از تغییرات غیرخطی موجود در رابطه بین دما و تقاضا را بهتر نمایش دهد.

با این حال، عملکرد این مدل‌ها همچنان نسبت به مدل چندمتغیره پایین‌تر است.

Evidence:

- Scatter Plot بین `temp` و `cnt`
- مقایسه R^2 مدل Linear و Polynomial

Conclusion

Polynomial Regression نسبت به Linear Regression تک‌متغیره عملکرد بهتری داشته است، اما استفاده از دما به تنهایی برای پیش‌بینی تقاضا کافی نیست. مدل‌های چندمتغیره به دلیل استفاده از اطلاعات بیشتر، عملکرد مناسب‌تری برای این مسئله دارند.

آیا مدل چند متغیره از مدل تک متغیره بهتر بوده است؟

مدل تک‌متغیره فقط از دما استفاده می‌کند:

- `temp` → `cnt`

اما مدل Multiple Regression از چندین ویژگی استفاده می‌کند:

`temp`

`hum`

`windspeed`

`yr`

`workingday`

`holiday`

↓

cnt

نتایج:

Model	Test R ²
Linear Regression (temp only)	-0.485
Multiple Linear Regression	+0.400

مدل چندمتغیره توانسته است نسبت به مدل تک‌متغیره بخش بیشتری از تغییرات تقاضا را توضیح دهد.

Evidence

- مقایسه مقدار R² مدل‌ها

Conclusion

مدل Multiple Regression عملکرد بهتری نسبت به مدل تک‌متغیره داشته است. دلیل این موضوع استفاده همزمان از چند ویژگی زمانی و آب‌وهوایی برای توضیح تغییرات تقاضا است.

چرا استفاده از casual و registered خطای مفهومی است؟

در دیتاست رابطه زیر وجود دارد:

$$\text{cnt} = \text{casual} + \text{registered}$$

بنابراین:

- casual تعداد کاربران غیرعضو است .
- registered تعداد کاربران عضو است .
- cnt مجموع کل کاربران است .

این دو ستون مستقیماً بخشی از مقدار هدف را تشکیل می‌دهند.

اگر این ویژگی‌ها وارد مدل شوند، مدل اطلاعاتی از پاسخ نهایی را قبل از پیش‌بینی دریافت می‌کند.

این مشکل باعث ایجاد **Target Leakage** می‌شود.

:Evidence

ساختار دیتاست و رابطه بین ستون‌ها.

:Conclusion

ستون‌های casual و registered نباید در مدل استفاده شوند، زیرا باعث ایجاد عملکرد غیرواقعی و ارزیابی اشتباه مدل می‌شوند.

چرا Train/Test زمانی برای این پروژه مناسب‌تر است؟

دیتاست دارای ساختار زمانی است و هدف پروژه پیش‌بینی تقاضای آینده است.

بنابراین داده‌ها به صورت زمانی تقسیم شدند:

Dataset	Date Range	Samples
Train	2011-01-01 تا 2012-08-07	584
Test	2012-08-07 تا 2012-12-31	147

در این روش:

Train → گذشته

Test → آینده

مدل ابتدا الگوهای گذشته را یاد می‌گیرد و سپس روی داده‌های آینده ارزیابی می‌شود.

:Evidence

- وجود ستون dteday
 - مرتب‌سازی زمانی داده‌ها
-

:Conclusion

تقسیم زمانی برای این پروژه مناسب‌تر است، زیرا ارزیابی مدل را به شرایط واقعی پیش‌بینی آینده نزدیک‌تر می‌کند. استفاده از Shuffle می‌تواند ترتیب زمانی داده‌ها را از بین ببرد و باعث شود داده‌های مربوط به دوره‌های آینده وارد مجموعه آموزش شوند.

آیا بین Train و Test تغییر توزیع مشاهده می‌شود؟

مقایسه آماری بین Train و Test نشان داد که میانگین تقاضا در دو بخش متفاوت است.

Dataset	Mean cnt
Train	4153.60
Test	5897.80

این اختلاف نشان‌دهنده تغییر سطح تقاضا بین دو دوره زمانی است.

این تغییر می‌تواند تحت تأثیر عواملی مانند:

- تفاوت فصل‌ها
- تغییر رفتار کاربران
- روند زمانی رشد سیستم

باشد.

این عوامل به عنوان دلایل احتمالی مطرح می‌شوند و برای اثبات اثر هر کدام نیاز به تحلیل جداگانه وجود دارد.

Evidence:

- مقایسه Mean و Distribution داده‌های Train و Test

Conclusion:

بین Train و Test تغییر توزیع مشاهده می‌شود و این موضوع باید هنگام تفسیر عملکرد مدل در نظر گرفته شود.

Scale چه اثری بر ضرایب و عملکرد داشته است؟

برای بررسی اثر Scaling ، مدل Multiple Regression قبل و بعد از استفاده از StandardScaler مقایسه شد.

نتایج:

Model	Test R ²
Multiple Regression	≈0.400
Scaled Multiple Regression	≈0.400

StandardScaler ویژگی‌های ورودی مدل را به مقیاسی با:

- میانگین صفر
- انحراف معیار واحد

تبدیل می‌کند.

:Evidence

- مقایسه R² قبل و بعد Scaling
- مقایسه ضرایب مدل

:Conclusion

Scaling باعث افزایش مقدار R² یا بهبود قابل توجه عملکرد مدل نشده است.

اثر اصلی Scaling در این پروژه، تغییر مقیاس ضرایب و ساده‌تر شدن مقایسه آن‌ها بوده است.

چه متغیرهای مهمی در دیتاست وجود ندارند؟

تقاضای دوچرخه تنها به عوامل آبوهوایی و زمانی محدود نیست.

برخی ویژگی‌های مهم که در دیتاست وجود ندارند:

Missing Feature	Possible Effect
Price / Rental Cost	اثر روی تصمیم کاربران
Events	تغییرات ناگهانی تقاضا
Location	تفاوت تقاضا در مناطق مختلف
Public Transport Availability	وجود جایگزین حمل‌ونقل
Fuel Price	اثر بر انتخاب روش حمل‌ونقل
User Demographics	تفاوت رفتار گروه‌های مختلف کاربران

Conclusion

اضافه کردن این ویژگی‌ها در آینده می‌تواند اطلاعات بیشتری درباره رفتار کاربران فراهم کند و احتمالاً باعث بهبود مدل شود؛ البته این موضوع باید با آزمایش مدل بررسی شود.

جمع‌بندی نهایی پروژه

نتایج تحلیل‌های انجام‌شده در این پروژه نشان داد که:

- توزیع تقاضای روزانه دوچرخه (cnt) کاملاً از توزیع نرمال پیروی نمی‌کند و انحراف‌هایی نسبت به توزیع نرمال مشاهده می‌شود. بنابراین برای تحلیل و پیش‌بینی تقاضا باید عوامل مختلف مؤثر بر تغییرات آن در نظر گرفته شوند .
- در میان متغیرهای آبوهوایی بررسی‌شده، دما (temp) قوی‌ترین رابطه خطی را با تقاضای روزانه دوچرخه (cnt) دارد. با این حال، این رابطه یک رابطه آماری است و به معنی اثر علی قطعی دما بر تقاضا نیست .
- مدل‌های مبتنی بر تنها ویژگی دما، شامل Linear Regression و Polynomial Regression، توانایی محدودی در توضیح تغییرات تقاضا دارند. اگرچه مدل Polynomial نسبت به Linear Regression تک‌متغیره توانسته است رابطه دما و تقاضا را بهتر نمایش دهد، اما استفاده از دما به تنهایی برای پیش‌بینی دقیق تقاضا کافی نیست .
- مدل Multiple Linear Regression با استفاده از ویژگی‌های بیشتر شامل :

temp + hum + windspeed + yr + workingday + holiday

توانسته است عملکرد بهتری نسبت به مدل‌های تک‌متغیره داشته باشد و بخش بیشتری از تغییرات تقاضا را توضیح دهد.

- استفاده از ویژگی‌های casual و registered در مدل‌سازی یک خطای مفهومی ایجاد می‌کند، زیرا این دو متغیر مستقیماً بخشی از مقدار هدف (cnt) هستند :

cnt = casual + registered

بنابراین استفاده از آن‌ها باعث ایجاد Target Leakage و نمایش عملکرد غیرواقعی مدل خواهد شد.

- با توجه به ماهیت زمانی داده‌ها، تقسیم Train/Test به صورت زمانی برای این پروژه مناسب‌تر است. در این روش، مدل با استفاده از داده‌های گذشته آموزش داده شده و روی داده‌های آینده ارزیابی می‌شود که شرایط واقعی پیش‌بینی را بهتر شبیه‌سازی می‌کند .
- استفاده از StandardScaler باعث بهبود قابل توجه مقدار R^2 در مدل نهایی نشده است. اثر اصلی Scaling در این پروژه تغییر مقیاس ضرایب مدل و قرار دادن ویژگی‌ها در یک مقیاس قابل مقایسه بوده است .
- برخی عوامل مهم مانند ویژگی‌های اجتماعی، اقتصادی و شهری در دیتاست موجود نیستند. اضافه کردن ویژگی‌هایی مانند قیمت اجاره، رویدادها، موقعیت مکانی، شرایط حمل‌ونقل عمومی و اطلاعات کاربران در آینده می‌تواند اطلاعات بیشتری برای مدل فراهم کند و احتمالاً باعث بهبود عملکرد مدل شود .

نتیجه نهایی

بر اساس نتایج به‌دست‌آمده، مدل Multiple Linear Regression به دلیل استفاده همزمان از چندین ویژگی زمانی و آب‌وهوایی، مناسب‌ترین مدل بررسی‌شده برای این پروژه است. همچنین تحلیل‌ها نشان دادند که برای پیش‌بینی تقاضای دوچرخه، بررسی همزمان عوامل مختلف ضروری است و استفاده از یک متغیر منفرد مانند دما نمی‌تواند تمام تغییرات موجود در تقاضا را توضیح دهد.
