

بارگذاری دیتاست اولیه (Dataset Loading)

```
df = pd.read_csv("day.csv")

print("Dataset Loaded Successfully")
```

تحلیل:

در این مرحله، دیتاست اصلی پروژه از فایل day.csv بارگذاری شد.

هدف از این مرحله، ایجاد یک DataFrame اولیه برای بررسی ساختار داده‌ها، کیفیت داده‌ها و انجام مراحل بعدی تحلیل اکتشافی (EDA) و مدل‌سازی است.

این دیتاست مربوط به سیستم اشتراک دوچرخه (Bike Sharing) بوده و شامل اطلاعات مربوط به:

- ویژگی‌های زمانی
- شرایط آب‌وهوایی
- ویژگی‌های تقویمی
- تعداد اجاره‌های روزانه دوچرخه

است.

داده‌ها با موفقیت وارد محیط تحلیل شدند و برای بررسی‌های بعدی آماده هستند.

بررسی نمونه‌های اولیه داده (First & Last Rows)

```
df.head()

df.tail()
```

تحلیل:

در این مرحله، چند رکورد ابتدایی و انتهایی دیتاست بررسی شد تا ساختار کلی داده‌ها، نام ستون‌ها و نحوه ثبت مقادیر مشخص شود.

این بررسی کمک می‌کند قبل از شروع تحلیل:

- بارگذاری صحیح ستون‌ها بررسی شود.

- ساختار داده‌ها با انتظار پروژه تطبیق داده شود .

- ترتیب زمانی رکوردها بررسی شود.

داده‌ها دارای ساختار مورد انتظار هستند.

ترتیب زمانی داده‌ها قابل بررسی است.

با مشاهده رکوردهای ابتدایی و انتهایی مشخص شد که دیتاست شامل اطلاعات روزانه بوده و ستون‌های مورد نیاز برای تحلیل تقاضا در آن وجود دارند.

بررسی ابعاد دیتاست و نوع داده‌ها (Dataset Shape & Data Types)

```
print(df.shape)
print(df.dtypes)
```

Dataset Structure

بر اساس خروجی `df.shape`، ساختار اولیه دیتاست شامل موارد زیر است:

مقدار	ویژگی
731	Number of Rows
16	Number of Columns

Column Categories

Category	Columns
Identifier	instant
Date	dteday
Calendar Features	season, yr, mnth, holiday, weekday, workingday
Weather Features	weathersit, temp, atemp, hum, windspeed
User Information	casual, registered

Category	Columns
Target Variable	cnt

Analysis

بررسی نوع داده‌ها نشان داد که دیتاست شامل ترکیبی از:

- متغیرهای عددی
- متغیرهای دسته‌ای
- متغیر تاریخ

است.

ستون cnt به عنوان متغیر هدف پروژه انتخاب شد، زیرا نشان‌دهنده مجموع تقاضای روزانه دوچرخه است.

همچنین برخی ستون‌ها مانند casual و registered نیاز به بررسی بیشتر داشتند، زیرا ارتباط مستقیمی با متغیر هدف دارند و ممکن است باعث ایجاد Data Leakage شوند.

ساختار داده برای انجام تحلیل و مدل‌سازی مناسب است.

همچنین مشخص شد که قبل از مدل‌سازی، برخی ستون‌ها نیاز به بررسی بیشتری دارند؛ به‌خصوص ستون‌هایی که ممکن است باعث Data Leakage شوند.

تبدیل تاریخ و مرتب‌سازی داده‌ها (Date Conversion & Sorting)

```
df['dteday'] = pd.to_datetime(df['dteday'])
df = df.sort_values('dteday')
df.reset_index(drop=True, inplace=True)
```

تحلیل:

ستون dteday در ابتدا به صورت متنی ذخیره شده بود.

برای انجام تحلیل‌های زمانی، این ستون به فرمت Date تبدیل شد و داده‌ها بر اساس تاریخ مرتب شدند.

این مرحله اهمیت زیادی دارد زیرا:

- داده‌ها دارای ساختار زمانی هستند .
 - تقسیم Train/Test باید بر اساس ترتیب زمانی انجام شود .
 - مدل باید توانایی پیش‌بینی شرایط آینده را داشته باشد .
- تقسیم تصادفی داده‌ها (Shuffle) برای این پروژه مناسب نیست، زیرا می‌تواند ترتیب زمانی مشاهدات را از بین ببرد و باعث شود نمونه‌های مربوط به دوره‌های آینده در مجموعه آموزش قرار گیرند.

داده‌ها به ترتیب زمانی قرار گرفتند و برای تحلیل‌های زمانی و مدل‌سازی آماده شدند.

تعریف نقش ستون‌ها (Column Role Analysis)

تحلیل:

برای جلوگیری از استفاده اشتباه از ویژگی‌ها، نقش هر ستون در پروژه مشخص شد.

تقسیم بندی ستون‌ها:

Identifier Column

Instant: این ستون فقط شماره رکورد را نشان می‌دهد و اطلاعات قابل استفاده‌ای برای پیش‌بینی تقاضا ندارد. بنابراین در مدل‌سازی استفاده نمی‌شود.

Date Column

Dteday: این ستون برای موارد زیر استفاده می‌شود:

- مرتب‌سازی زمانی داده‌ها
 - ایجاد تقسیم Train/Test زمانی
-

Model Input Features

در این پروژه، برای مدل Multiple Linear Regression ویژگی‌های زیر به عنوان ورودی انتخاب شدند:

- temp •
- hum •
- windspeed •
- yr •
- workingday •
- holiday •

این انتخاب مطابق طراحی مدل پروژه انجام شده است و هدف، بررسی اثر همزمان عوامل آب‌وهوایی و زمانی بر تغییرات تقاضای روزانه دوچرخه است.

سایر ویژگی‌های موجود مانند:

- season •
- mnth •
- weekday •
- weathersit •
- atemp •

در مدل نهایی استفاده نشدند.

Target Variable

Cnt : این ستون نشان‌دهنده مجموع تعداد اجاره روزانه دوچرخه است.

رابطه:

cnt = Total Bike Demand

Leakage Columns

casual

registered

رابطه موجود:

cnt = casual + registered

این دو ستون مستقیماً بخشی از مقدار هدف را تشکیل می‌دهند.

نتیجه

ستون‌های casual و registered نباید به عنوان ویژگی ورودی مدل استفاده شوند، زیرا اطلاعات مستقیم درباره متغیر هدف دارند.

استفاده از این ستون‌ها باعث ایجاد Target Leakage می‌شود و عملکرد مدل را غیرواقعی نشان می‌دهد.

بررسی Duplicate Data و Missing Values

```
df.isnull().sum()
```

```
df.duplicated().sum()
```

Output

Check	Result
Missing Values	0
Fully Duplicated Rows	0

Analysis

در این مرحله، وجود مقادیر گم‌شده و رکوردهای کاملاً تکراری بررسی شد.

وجود Missing Values می‌تواند باعث:

- کاهش داده‌های قابل استفاده
- ایجاد مشکل در مدل‌سازی

شود.

همچنین رکوردهای کاملاً تکراری می‌توانند باعث ایجاد وزن غیرواقعی برای برخی نمونه‌ها شوند.

بر اساس بررسی انجام‌شده:

- هیچ مقدار گم‌شده‌ای در دیتاست مشاهده نشد.
- هیچ رکورد کاملاً تکراری وجود نداشت.

بنابراین داده‌ها از نظر Missing Values و Fully Duplicated Records آماده ادامه تحلیل هستند.

حذف ستون‌های غیرمناسب برای مدل‌سازی (Data Cleaning)

```
df_clean = df.drop(
columns=[
'instant',
'casual',
'registered'
])
```

تحلیل:

در این مرحله ستون‌هایی که برای مدل‌سازی مناسب نبودند حذف شدند.

Instant: به دلیل اینکه فقط شناسه رکورد است و اطلاعات پیش‌بینی‌کننده ندارد.

registered و **casual**: به دلیل ایجاد Target Leakage حذف شدند.

پس از حذف ستون‌های غیرمناسب:

- تعداد ستون‌ها از ۱۶ ستون اولیه به ۱۳ ستون کاهش یافت.

دیتاست پاک‌سازی‌شده شامل ویژگی‌های مناسب برای تحلیل و مدل‌سازی است.

بررسی آماری اولیه متغیرهای اصلی

```
df[['cnt', 'temp', 'hum', 'windspeed']].describe()
```

تحلیل:

در این مرحله آمار توصیفی متغیرهای اصلی بررسی شد.

هدف:

- شناخت محدوده مقادیر
- بررسی میانگین
- بررسی میزان پراکندگی داده‌ها

بود.

متغیرهای بررسی شده:

- cnt
- temp
- hum
- windspeed

نتایج نشان داد که مقدار تقاضا (cnt) در طول روزهای مختلف تغییرات قابل توجهی دارد.

این تغییرات نشان می‌دهد که تقاضای دوچرخه تحت تأثیر عوامل مختلف قرار دارد و استفاده از چند ویژگی برای مدل‌سازی مناسب‌تر است.

تحلیل روزهای با تقاضای بالا (90th Percentile)

```
threshold = df['cnt'].quantile(0.90)
high_demand_days = df[
df['cnt'] > threshold
]
```

Output

90th Percentile Threshold = 7290

High Demand Days = 73

Analysis

در این بخش، روزهایی که مقدار تقاضای آنها در ۱۰ درصد بالایی داده‌ها قرار دارد شناسایی شدند.

Threshold مربوط به صدک ۹۰ محاسبه شد و رکوردهایی که مقدار cnt آنها بیشتر از این مقدار بود به عنوان روزهای High Demand مشخص شدند.

روزهایی که مقدار:

$cnt > 7290$

داشتند به عنوان روزهای با تقاضای بالا شناسایی شدند.

این تحلیل می‌تواند در بررسی الگوهای مرتبط با افزایش تقاضا در مراحل بعدی استفاده شود

جمع‌بندی بخش آماده‌سازی دیتاست

نتیجه کلی

- دیتاست با موفقیت بارگذاری شد .
- ساختار و نوع داده‌ها بررسی شد .
- ستون تاریخ تبدیل و داده‌ها مرتب شدند .
- Missing Values و Fully Duplicated Records بررسی شدند .
- ستون‌های غیرمناسب و دارای Target Leakage حذف شدند .
- ویژگی‌های مورد استفاده در مدل نهایی مشخص شدند.