

تحلیل بخش مدل سازی پروژه پیش بینی تقاضای روزانه دوچرخه

آماده سازی داده ها برای مدل سازی (Model Preparation)

هدف:

پس از انجام مراحل بررسی اولیه داده ها و تحلیل اکتشافی (EDA)، مرحله مدل سازی با هدف پیش بینی مقدار تقاضای روزانه دوچرخه (cnt) انجام شد.

در این مرحله هدف اصلی، ساخت مدل هایی است که بتوانند با استفاده از ویژگی های موجود، تغییرات تقاضای روزانه را توضیح داده و روی داده های جدید عملکرد مناسبی داشته باشند.

تعریف متغیر هدف (Target Variable)

در این پروژه متغیر هدف Cnt انتخاب شد.

این متغیر نشان دهنده مجموع تعداد اجاره روزانه دوچرخه است.

رابطه موجود در دیتاست:

$$cnt = casual + registered$$

به همین دلیل ستون های casual و registered به عنوان ویژگی ورودی مدل استفاده نشدند.

جلوگیری از Target Leakage

دو ستون casual و registered شامل اطلاعاتی هستند که مستقیماً بخشی از مقدار هدف (cnt) را تشکیل می دهند.

اگر این دو ویژگی وارد مدل شوند، مدل قبل از پیش بینی، اطلاعاتی از پاسخ نهایی را در اختیار خواهد داشت.

این موضوع باعث ایجاد:

Target Leakage

می شود.

نتیجه

برای جلوگیری از ایجاد دقت غیرواقعی، این دو ویژگی از تمام مدل های پروژه حذف شدند.

ویژگی‌های مورد استفاده در مدل نهایی مطابق مشخصات پروژه:

- temp
- hum
- windspeed
- yr
- workingday
- holiday

تقسیم داده‌ها به Train و Test به صورت زمانی

هدف:

از آنجا که دیتاست ماهیت زمانی دارد، تقسیم تصادفی داده‌ها (Random Split) برای این پروژه مناسب نیست. در مسائل پیش‌بینی زمانی، هدف مدل این است که با استفاده از داده‌های گذشته، شرایط آینده را پیش‌بینی کند. بنابراین تقسیم داده‌ها به صورت زمانی انجام شد:

Train → گذشته

Test → آینده

یعنی Scaler نباید روی کل داده قبل از تقسیم Train/Test fit شود.

روش تقسیم Train/Test

داده‌ها ابتدا بر اساس تاریخ مرتب شده‌اند. سپس:

- 80 درصد ابتدایی داده‌ها برای آموزش مدل
- 20 درصد انتهایی داده‌ها برای ارزیابی مدل

در نظر گرفته شدند. نتایج:

Dataset	Number of Samples	Date Range
Train	584	2011-01-01 تا ۲۰۱۲-۰۸-۰۶
Test	147	2012-08-07 تا ۲۰۱۲-۱۲-۳۱

دلیل انتخاب Temporal Split

استفاده از تقسیم زمانی باعث می شود ارزیابی مدل به شرایط واقعی نزدیک تر باشد. در این حالت مدل روی داده هایی آزمایش می شود که در زمان آموزش مشاهده نکرده است. استفاده از Shuffle ترتیب زمانی داده ها را از بین می دهد و می تواند باعث شود نمونه هایی از دوره های آینده در مجموعه آموزش قرار گیرند؛ بنابراین ارزیابی مدل دیگر کاملاً مشابه سناریوی واقعی پیش بینی آینده نخواهد بود.

بررسی تغییر توزیع بین Train و Test

پس از تقسیم داده ها، توزیع متغیر هدف در دو بخش مقایسه شد.

نتایج:

Dataset	Mean cnt
Train	4153.60
Test	5897.80

تحلیل:

بین میانگین تقاضای Train و Test اختلاف مشاهده شد.

این اختلاف نشان می دهد که سطح کلی تقاضا در دوره زمانی Test نسبت به Train تغییر کرده است.

این تغییر می تواند ناشی از عواملی مانند:

- روند زمانی رشد سیستم
- تغییر رفتار کاربران
- تفاوت فصل ها در دو بازه زمانی

باشد.

وجود تغییر توزیع بین Train و Test باید هنگام تفسیر عملکرد مدل در نظر گرفته شود.

با این حال، استفاده از Temporal Split همچنان روش مناسب تری است، زیرا هدف پروژه پیش بینی آینده است.

جمع بندی این بخش

در مرحله آماده سازی مدل:

- متغیر هدف cnt مشخص شد.
 - ستون هایی که باعث Target Leakage می شوند حذف شدند.
 - ویژگی های نهایی مدل مطابق قرارداد پروژه انتخاب شدند.
 - تقسیم Train/Test به صورت زمانی انجام شد.
 - تغییر توزیع بین داده های آموزش و آزمایش شناسایی و گزارش شد.
- این آماده سازی باعث شد ارزیابی مدل ها واقع بینانه تر بوده و عملکرد آن ها روی داده های آینده بررسی شود.