

گزارش مدیریتی پروژه

مشکلاتی که باید تحلیلگر و معمار اصلاح کنند + راه حل دقیق

این متن را از طرف خودم به تیم می‌دهم:

من فایل نهایی پروژه رو بررسی کردم. نتیجه کلی کار خوبه و بخش زیادی از تحلیل و مدل سازی انجام شده، اما چند مورد هست که قبل از تحویل نهایی باید اصلاح و یکدست بشه. من نمی‌خوام فقط بگیم «مشکل داریم»؛ برای هر مورد مشخص کردم مشکل کجاست، چه کسی باید بررسیش کنه و دقیقاً چه چیزی باید اصلاح بشه.

۱. اولویت اصلی: یک نسخه نهایی و مرجع داشته باشیم

مشکل: داخل فایل پروژه چند notebook و چند نسخه از فایل‌ها وجود دارد. این باعث می‌شود معلوم نباشد کدام notebook نسخه نهایی و قابل تحویل است.

راه حل مدیریتی من: فقط یک notebook را به عنوان نسخه نهایی مشخص می‌کنیم و بقیه نسخه‌های آزمایشی از مسیر تحویل نهایی خارج می‌شوند.

مسئول اصلی: معمار

از معمار می‌خوام:

- یک notebook اصلی و نهایی تعیین کند.
- نسخه‌های قدیمی و آزمایشی را از ساختار تحویل نهایی جدا کند.
- ساختار نهایی پروژه را طوری بچیند که مشخص باشد داده، notebook، گزارش و مستندات هر کدام کجا هستند.
- بعد از یکپارچه سازی، همان نسخه‌ای که تحویل می‌دهیم باید نسخه‌ای باشد که اجرا و بررسی شده است.

۲. مسیر فایل داده باید با ساختار نهایی یکی باشد

مشکل: notebook اصلی در نسخه فعلی از مسیر مربوط به ساختار قدیمی پروژه برای خواندن day.csv استفاده می‌کند، در حالی که در ساختار نهایی باید داده در مسیر مشخص data/raw باشد.

راه‌حل: مسیر خواندن داده در notebook نهایی با ساختار نهایی پروژه هماهنگ شود و بعد کل notebook از ابتدا اجرا شود.

مسئول اصلی: معمار

از معمار می‌خواهم:

مسیر داده را اصلاح کند و مطمئن شود notebook نهایی روی یک سیستم دیگر هم با همان ساختار پروژه قابل اجراست.

۳. تحلیلگر باید نتیجه EDA را فقط عدد ندهد؛ تفسیر هم باید دقیق باشد

نتیجه فعلی: همبستگی cnt با temp حدود $+0.627$ ، با hum حدود -0.101 و با windspeed حدود -0.235 گزارش شده و temp قوی‌ترین رابطه خطی بین متغیرهای آب‌وهوایی بررسی‌شده را دارد.

راه‌حل: تفسیر نهایی این باشد که «دما در بین متغیرهای آب‌وهوایی بررسی‌شده، قوی‌ترین رابطه خطی با cnt را دارد».

مسئول اصلی: تحلیلگر

از تحلیلگر می‌خواهم:

متن تفسیر نمودارها و correlation matrix را با همین ادبیات اصلاح کند و از عبارات‌های قطعی و علی استفاده نکند.

۴. دما به تنهایی مدل نهایی نیست

مشکل احتمالی در برداشت: چون temp بیشترین همبستگی را دارد، ممکن است تصور شود مدل نهایی باید فقط با temp ساخته شود.

راه حل: مدل های temp-only برای مقایسه و بررسی رابطه دما و تقاضا هستند. مدل Multiple طبق صورت پروژه باید از temp، hum، windspeed، yr، workingday و holiday استفاده کند.

مسئول: تحلیلگر نتیجه را درست توضیح دهد؛ معمار قرارداد ویژگی ها را کنترل کند.

نکته ای که باید در نسخه نهایی ثابت بماند:

Multiple Linear Regression = temp + hum + windspeed + yr + workingday + holiday

ویژگی های casual و registered نباید وارد مدل شوند، چون cnt برابر مجموع آنهاست و استفاده از آنها باعث Target Leakage می شود.

۵. تقسیم Train و Test باید زمانی باقی بماند

نتیجه فعلی: 584 رکورد برای Train و 147 رکورد برای Test استفاده شده؛ Train از 01-01-2011 تا 2012-08-06 و Test از 07-08-2012 تا 31-12-2012 است.

مشکل: میانگین cnt در Train حدود 4153.60 و در Test حدود 5897.80 است؛ بنابراین سطح تقاضا بین دو بخش تغییر کرده است.

راه حل: این نتیجه باید در گزارش بماند و Test نباید با Shuffle ساخته شود. برای این پروژه، Test باید نقش آینده را شبیه سازی کند.

مسئول: معمار کنترل فنی؛ تحلیلگر تفسیر نتیجه.

۶. R^2 منفی را حذف یا پنهان نکنیم

نتیجه فعلی: Linear با temp در Test حدود -0.485، Polynomial درجه 2 حدود -0.317 و درجه 3 حدود -0.314 هستند. Multiple به حدود +0.400 رسیده است.

راه حل: این اعداد باید همان طور که هستند گزارش شوند. توضیح ما این است که مدل های تک متغیره و چند جمله ای روی Test تعمیم ضعیفی داشته اند و مدل Multiple عملکرد بهتری دارد.

مسئول: تحلیلگر برای تفسیر؛ معمار برای کنترل اینکه اعداد در notebook و گزارش یکی باشند.

۷. StandardScaler باید درست اجرا و توضیح داده شود

نتیجه فعلی: Multiple و Multiple + StandardScaler هر دو R^2 Test حدود 0.400 دارند. Scaling پیش بینی ها و R^2 را تغییر نداده و فقط مقیاس ضرایب را تغییر داده است.

راه حل: StandardScaler فقط روی Train fit شود و بعد روی Train و Test transform شود. در دفاع هم نگوییم «Scaling دقت را بهتر کرد»، چون در این مدل چنین اتفاقی نیفتاده است.

مسئول اصلی: معمار برای کنترل اجرای صحیح؛ تحلیلگر/مدل ساز برای توضیح نتیجه.

۸. ضرایب مدل را نباید اشتباه تفسیر کنیم

نتیجه فعلی: ضرایب مدل شامل temp حدود +6113.59، hum حدود -1960.74، windspeed حدود -3736.14، yr حدود +1742.74، workingday حدود +29.79 و holiday حدود -442.74 است.

نکته مهم: temp، hum و windspeed در این دیتاست نرمال شده اند؛ پس نباید بگوییم «یک درجه افزایش دما 6113 اجاره اضافه می کند».

راه حل: ضرایب را به عنوان اثر شرطی/رابطه مدل، با ثابت نگه داشتن سایر ویژگی ها توضیح دهیم؛ نه به عنوان رابطه علی قطعی.

مسئول: تحلیلگر

۹. پنج پیش‌بینی اول باید با نتیجه نهایی یکی باشند

برای Test، پنج ردیف اول باید با خروجی نهایی مدل مطابقت داشته باشند:

- 2012-08-07: واقعی 7273، پیش‌بینی 6853.84
- 2012-08-08: واقعی 7534، پیش‌بینی 7024.10
- 2012-08-09: واقعی 7286، پیش‌بینی 6993.08
- 2012-08-10: واقعی 5786، پیش‌بینی 6252.42
- 2012-08-11: واقعی 6299، پیش‌بینی 6167.29

مسئول: معمار باید کنترل کند که این خروجی از همان notebook نهایی تولید شده باشد و گزارش هم همان اعداد را داشته باشد.

۱۰. گزارش، README و notebook باید یک حرف بزنند

مشکل: اگر چند نسخه از notebook و فایل‌ها وجود داشته باشد یا README به نام فایلی اشاره کند که در نسخه نهایی وجود ندارد، تحویل پروژه نامنظم دیده می‌شود.

راه‌حل: بعد از مشخص شدن notebook نهایی، نام فایل‌ها، مسیرها و توضیحات README با همان نسخه هماهنگ شوند.

مسئول اصلی: معمار

کنترل نهایی:

- اعداد R^2 در notebook و گزارش یکی باشد.
- تاریخ‌های Train و Test یکی باشد.
- ویژگی‌های مدل نهایی یکی باشد.
- پنج پیش‌بینی اول یکی باشد.
- نام notebook و مسیر فایل‌ها واقعی و قابل دسترسی باشد.

۱۱. جمع‌بندی کاری که من از هر نفر می‌خوام

از تحلیلگر:

- EDA را یک بار نهایی و دقیق بررسی کند.
- تفسیر correlation را اصلاح کند.
- نتایج توزیع، سال‌ها، آب‌وهوا و رابطه متغیرها را درست توضیح دهد.
- توضیح R^2 منفی و بهتر بودن Multiple را آماده کند.
- ضرایب را بدون تفسیر علی و اشتباه توضیح دهد.

از معمار:

- ساختار پروژه را نهایی و تمیز کند.
- یک notebook مرجع مشخص کند.
- مسیر day.csv را با ساختار نهایی هماهنگ کند.
- قرارداد ویژگی‌های مدل را کنترل کند.
- Train/Test زمانی و StandardScaler را کنترل کند.
- notebook را از ابتدا تا انتها بدون خطا اجرا کند.
- README، گزارش و notebook را با هم یکسان کند.

وظیفه من به عنوان مدیر:

من خروجی هر دو نفر رو می‌گیرم، با صورت پروژه و نسخه نهایی مقایسه می‌کنم، اختلاف‌ها رو برمی‌گردونم برای اصلاح، بعد از تأیید همه بخش‌ها نسخه نهایی رو برای تحویل و دفاع آماده می‌کنم.

پیام آماده برای فرستادن در گروه

بچه‌ها من فایل نهایی رو به عنوان مدیر پروژه بررسی کردم. کار کلی جلو رفته، ولی قبل از تحویل چند مورد باید حتماً اصلاح بشه. تحلیلگر لطفاً بخش EDA و تفسیر نتایج رو دوباره چک کن، مخصوصاً نحوه توضیح همبستگی دما، R^2 منفی مدل‌های تک‌متغیره و تفسیر ضرایب. معمار لطفاً ساختار نهایی پروژه، یکسان بودن notebook نهایی، مسیر day.csv، قرارداد ویژگی‌های مدل، Train/Test زمانی، StandardScaler و هماهنگی README و گزارش با notebook رو بررسی کن. لطفاً بعد از اصلاح، نسخه‌ای که تحویل می‌دید همون نسخه‌ای باشه که از اول تا آخر اجرا شده و خطا نداشته باشه. من بعدش همه خروجی‌ها رو یک بار نهایی با هم تطبیق می‌دم و نسخه تحویل رو می‌بندم.

مبنای این گزارش، نتایج فایل نهایی پروژه و الزامات پروژه است؛ هدفش مشخص کردن دقیق کار اصلاحی برای تحلیلگر و معمار از دید مدیر پروژه است.