

پروژه تحلیل و پیش‌بینی تقاضای روزانه دوچرخه‌های اشتراکی

سناریوی پروژه

مدیریت حمل‌ونقل یک شهر قصد دارد تعداد دوچرخه‌های موردنیاز در روزهای آینده را تخمین بزند. کمبود دوچرخه باعث نارضایتی کاربران و مزاد آن باعث افزایش هزینه جابه‌جایی و نگهداری می‌شود. تیم شما باید بررسی کند که دما، رطوبت، سرعت باد، تعطیلات و شرایط زمانی چه ارتباطی با تعداد اجاره روزانه دوچرخه دارند و سپس چند مدل برای پیش‌بینی تقاضا ایجاد کند. مدت انجام پروژه یک هفته است و پروژه باید توسط یک تیم سه‌نفره انجام شود.

معرفی دیتاست

در این پروژه از دیتاست Bike Sharing استفاده می‌شود. داده‌ها مربوط به تعداد اجاره دوچرخه در سال‌های ۲۰۱۱ و ۲۰۱۲ همراه با اطلاعات آب‌وهوا، فصل و روزهای کاری است.

مجموعه اصلی دو فایل دارد:

- hour.csv : اطلاعات ساعتی

- day.csv : اطلاعات روزانه

در این پروژه فقط باید از فایل day.csv استفاده شود.

ستون‌های مهم عبارت‌اند از:

- dteday: تاریخ
- season: فصل به صورت کد دسته‌ای
- yr: سال
- mnth: ماه
- holiday: تعطیل بودن روز
- weekday: روز هفته
- workingday: روز کاری
- weathersit: وضعیت آب‌وهوا به صورت کد دسته‌ای

- temp: دمای نرمال شده
- atemp: دمای احساسی نرمال شده
- hum: رطوبت نرمال شده
- windspeed: سرعت باد نرمال شده
- casual: تعداد کاربران عادی
- registered: تعداد کاربران ثبت شده
- cnt: مجموع کل اجاره‌ها؛ متغیر هدف

منبع رسمی و توضیحات دیتاست [UCI Bike Sharing](https://archive.ics.uci.edu/static/public/275/bike%2Bsharing%2Bdataset.zip) در UCI:

دانلود مستقیم : <https://archive.ics.uci.edu/static/public/275/bike%2Bsharing%2Bdataset.zip>

شناسه دیتاست در بسته ucimlrepo برابر 275 است.

هدف اصلی

پاسخ دادن به این سؤال:

آیا می‌توان تقاضای روزانه دوچرخه اشتراکی را با استفاده از شرایط آب‌وهوایی و اطلاعات روز پیش‌بینی کرد؟

مراحل الزامی پروژه

۱. شناخت و آماده‌سازی داده

- فایل day.csv را بارگذاری کنید.
- پنج سطر اول و آخر را نمایش دهید.
- تعداد سطرها، ستون‌ها و انواع داده را گزارش کنید.
- ستون dteday را به نوع Date تبدیل کنید.
- داده‌ها را بر اساس تاریخ مرتب کنید.
- متغیر هدف را cnt در نظر بگیرید.
- نقش هر ستون را در قالب یک جدول توضیح دهید.
- ستون‌ها را به Binary، Numerical، Categorical Coded، Date، ID و Target تقسیم کنید.

۲. بررسی کیفیت و جلوگیری از Data Leakage

- مقادیر گم شده و داده های تکراری را بررسی کنید.
- ستون `instant` را از مدل حذف کنید؛ زیرا فقط شناسه رکورد است.
- ستون های `casual` و `registered` را از تمام مدل ها حذف کنید.
- دلیل حذف این دو ستون را توضیح دهید.

نکته اصلی:

$$\text{cnt} = \text{casual} + \text{registered}$$

بنابراین استفاده از `casual` و `registered` برای پیش بینی `cnt` باعث Data Leakage می شود؛ زیرا اجزای پاسخ مستقیماً در اختیار مدل قرار می گیرند.

۳. آمار توصیفی

برای ستون های `cnt`، `temp`، `hum` و `windspeed` موارد زیر را محاسبه کنید:

- Mean
- Median
- Mode
- Standard Deviation
- Maximum و Minimum
- صدک های ۲۵، ۵۰، ۷۵ و ۹۰

سپس:

- روزهای بالاتر از صدک ۹۰ تقاضا را جدا کنید.
- ویژگی های آب و هوایی این روزها را بررسی کنید.
- میانگین `cnt` را به تفکیک `season`، `workingday` و `weathersit` محاسبه کنید.
- اگر `cnt` یک Mode یکتای معنادار نداشت، علت آن را توضیح دهید.

۴. تحلیل توزیع

- Histogram متغیر cnt را رسم کنید.
- Histogram متغیرهای temp, hum و windspeed را رسم کنید.
- یک توزیع Normal مصنوعی با Mean و Standard Deviation متغیر cnt ایجاد کنید.
- شکل توزیع واقعی و Normal مصنوعی را مقایسه کنید.
- درباره متقارن یا نامتقارن بودن توزیع تقاضا بحث کنید.
- توزیع cnt در سال ۲۰۱۱ و ۲۰۱۲ را جداگانه مقایسه کنید.

۵. Scatter Plot

حداقل نمودارهای زیر را رسم کنید:

- temp در برابر cnt
- hum در برابر cnt
- windspeed در برابر cnt

برای هر نمودار توضیح دهید:

- جهت رابطه
- شدت تقریبی رابطه
- خطی یا غیر خطی بودن الگو
- وجود نقاط پرت
- تأثیر احتمالی فصل یا سال بر شکل نمودار

۶. Train/Test زمانی

این دیتاست دارای ترتیب زمانی است. بنابراین تقسیم کاملاً تصادفی می‌تواند اطلاعات روزهای آینده را وارد بخش Train کند.

روش اصلی تقسیم:

- داده‌ها را براساس dteday مرتب کنید.
- ۸۰ درصد ابتدایی داده را Train در نظر بگیرید.
- ۲۰ درصد انتهایی را Test در نظر بگیرید.

- ترتیب زمانی نباید به هم بخورد.
 - بازه تاریخی Train و Test را گزارش کنید.
 - Mean, Standard Deviation و توزیع cnt را در دو بخش مقایسه کنید.
- این روش با مفهوم ۲۰/۸۰ بخش [Train/Test](#) در [W3Schools](#) هماهنگ است، اما به دلیل ماهیت زمانی داده، تقسیم به صورت زمانی انجام می شود.

۷. Linear Regression

یک مدل Linear Regression ساده ایجاد کنید:

- ورودی temp :

- خروجی cnt :

الزامات:

- آموزش فقط با داده Train
- پیش‌بینی برای Train و Test
- رسم خط رگرسیون روی Scatter Plot
- محاسبه R^2 برای Train و Test
- تفسیر شیب خط
- توضیح اینکه چرا دما به‌تنهایی برای پیش‌بینی تقاضا کافی نیست

۸. Polynomial Regression

برای رابطه temp و cnt مدل Polynomial ایجاد کنید:

- درجه ۲

- درجه ۳

برای هر مدل:

- منحنی رگرسیون را رسم کنید.
- R^2 برای Train و Test را محاسبه کنید.

- نتیجه را با مدل Linear مقایسه کنید.
- وجود Overfitting یا Underfitting را بررسی کنید.
- پیش‌بینی خارج از محدوده دمای مشاهده‌شده انجام ندهید.

۹. Multiple Regression

مدل Multiple Linear Regression را با ویژگی‌های زیر ایجاد کنید:

- temp •
- hum •
- windspeed •
- yr •
- workingday •
- holiday •

از temp و atemp به‌صورت هم‌زمان استفاده نکنید؛ زیرا هر دو مفهوم دمای مشابهی را نمایش می‌دهند.

ستون‌های زیر در مدل اصلی وارد نشوند:

- instant •
- dteday •
- casual •
- registered •
- season •
- mnth •
- weekday •
- weathersit •

چهار ستون آخر کدهای دسته‌ای هستند و استفاده مستقیم از آن‌ها به‌عنوان عدد پیوسته می‌تواند ترتیب و فاصله‌ای غیرواقعی ایجاد کند.

الزامات:

- آموزش مدل با داده Train

- محاسبه R^2 برای Train و Test
- نمایش و تفسیر ضرایب
- مقایسه مدل چندمتغیره با مدل های مبتنی بر دما
- نمایش مقدار واقعی و پیش بینی شده پنج روز اول Test

۱۰. Scale

- ویژگی های مدل چندمتغیره را با StandardScaler استاندارد کنید.
- Scaler فقط با داده Train آموزش داده شود.
- Test با همان Scaler تبدیل شود.
- مدل را قبل و بعد از Scale اجرا کنید.
- R^2 و ضرایب دو مدل را مقایسه کنید.
- توضیح دهید چرا بعضی ویژگی های این دیتاست از قبل Normalized شده اند و Scale مجدد چه اثری دارد.

مقایسه نهایی ۱۱.

جدول زیر را تکمیل کنید:

نتیجه R^2 Train و ویژگی ها مدل

Linear temp

Polynomial درجه ۲ temp

Polynomial درجه ۳ temp

چند ویژگی Multiple Regression

چند ویژگی Multiple Regression + Scale

اگر R^2 مربوط به Test منفی شد، نتیجه را حذف یا مخفی نکنید. توضیح دهید که مدل در پیش بینی داده های آینده ضعیف تر از یک پیش بینی ساده مبتنی بر میانگین عمل کرده است.

پرسش های تحلیلی نهایی

1. آیا تقاضای روزانه دوچرخه تقریباً Normal است؟
2. دما، رطوبت یا سرعت باد کدام رابطه روشن‌تری با تقاضا دارد؟
3. آیا Polynomial Regression رابطه دما و تقاضا را بهتر نمایش داد؟
4. آیا مدل چندمتغیره از مدل تک‌متغیره بهتر بود؟
5. چرا استفاده از casual و registered خطای مفهومی محسوب می‌شود؟
6. چرا Train/Test زمانی برای این پروژه مناسب‌تر است؟
7. آیا میان Train و Test تغییر توزیع مشاهده می‌شود؟
8. Scale چه اثری بر ضرایب و عملکرد مدل داشت؟
9. چه متغیرهای مهمی در دیتاست وجود ندارند که می‌توانند روی تقاضا اثر بگذارند؟

خروجی‌های موردنیاز

- Jupyter Notebook کامل و قابل اجرای مجدد
- گزارش PDF بین ۴ تا ۶ صفحه
- فایل README.md شامل منبع داده، روش اجرا و مسئولیت اعضا
- فایل اصلی day.csv و در صورت تولید، نسخه پردازش‌شده
- ارائه ۸ تا ۱۰ دقیقه‌ای با مشارکت تمام اعضا